| Date : 2021.06.20

우아한형제들 사전과제

홍남표

Contents

1

ResNet paper review
(Deep Residual Learning for Image Recognition)

Introduction

AlexNet, VGGNet 등 ILSVRC competition(image classification) winner 모델들은 Convolution layer 를 깊게 쌓음으로써 분류 성능을 향상시킴

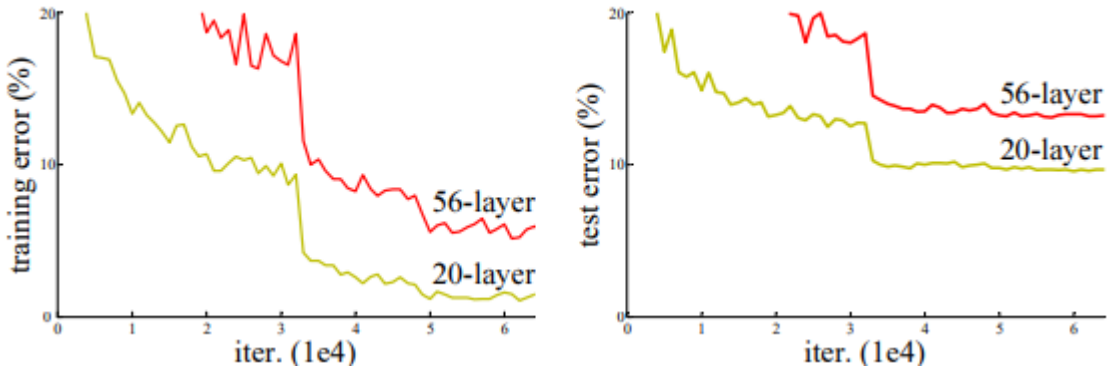

실제로는 conv layer를 깊게 쌓을수록 여러 문제가 발생함

1. vanishing/exploding gradients 로 인해 학습 초기부터 convergence 방해
    - normalized initialization, intermediate normalization layers(BatchNorm layers) 로 해결
2. deeper network 가 수렴을 시작할 때, degradation 문제가 발생함
    - network depth가 증가할수록, accuracy가 포화상태에 이르고, 빠르게 감소하기 시작
    - overfitting 의 문제는 아님(adding more layer -> higher training error)

-> degradation problem 을 해결하기 위한 deep residual learning framework 제안

Deep Residual Learning – Baseline Network Architectures

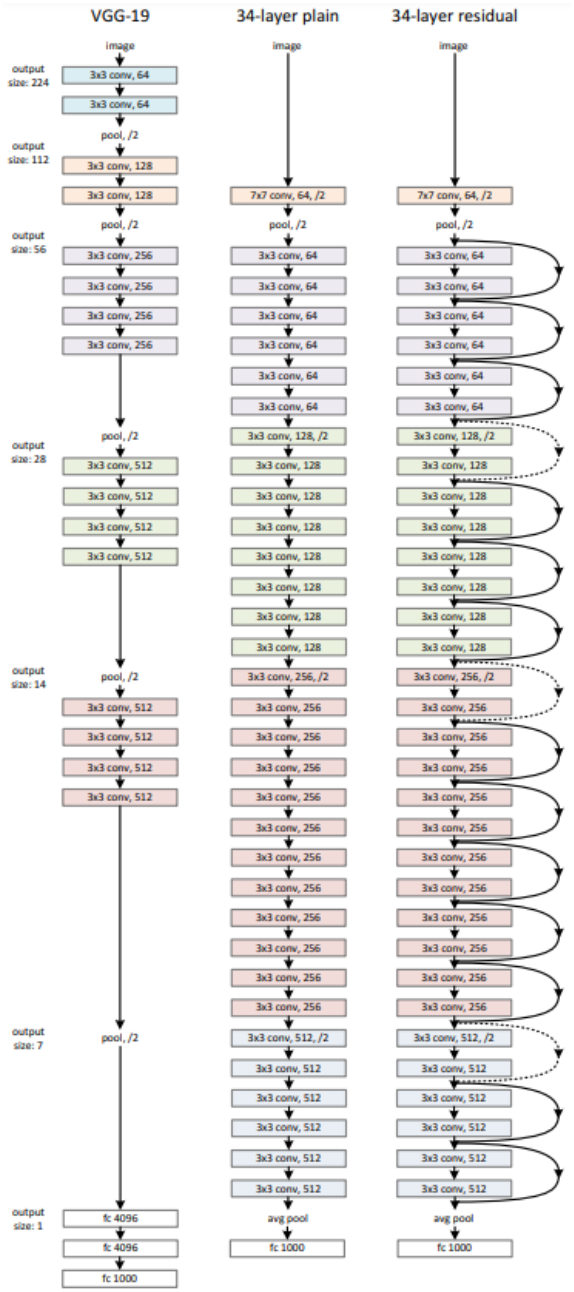

Plain Network	- VGG net 에 많은 영감을 받음 (3x3 크기의 convolution filter 를 거의 모든 레이어에서 사용) - 두가지 Design Rules 1. 같은 output feature map 크기에 대해서는, 같은 수의 filter를 사용한다 2. feature map 크기가 절반으로 줄어들 경우, filter 수는 2배로 증가 - Downsampling stride : 2 - 마지막 fc layer 전에 global average pooling - 1000-way(ImageNet) fully-connected layer + softmax - Weight layer 의 총 개수 : 34
Residual Network	- Plain network 를 기반으로, shortcut connection을 추가함 - input feature dim == output feature dim 일 경우, identity shortcuts 사용 - output feature 의 dimension 이 증가할 경우 2가지 옵션이 고려됨 1. 증가한 dimension 에 대한 extra padding 을 수행한 다음 identity mapping 2. 1x1 convolution 을 이용한 projection shortcut - 두 옵션 모두 feature map size 는 2배로 증가하고, stride 2로 진행함

Deep Residual Learning – Train Details

Categories	Details
Preprocessing	- 이미지는 단축 기준 [256, 480] 크기로 randomly sampled 되는 scale augmentation 수행 - 224x224 size 로 random crop - random horizontal flip - per-pixel mean subtracted - standard color augmentation
Regularization	- 각 convolution layer 뒤, activation layer 앞에 batch normalization 적용 - Dropout 은 사용하지 않음
Initialization	- He initialization 적용 - 모든 plain, residual nets 는 scratch 에서 학습 진행
Optimizer	- Stochastic gradient descent, mini-batch size 256 - learning rate : 0.1 부터 시작해서, validation error 가 감소하지 않으면 10으로 나눠 줌 - weight decay 0.0001, momentum 0.9
Dataset	- ImageNet 2012 classification dataset - 1000 classes, 1.28M train images, 50k validation images, 100k test images
Evaluation Metrics	- Top-1 error rates - Top-5 error rates

Experiments – ImageNet Classification – Residual Networks

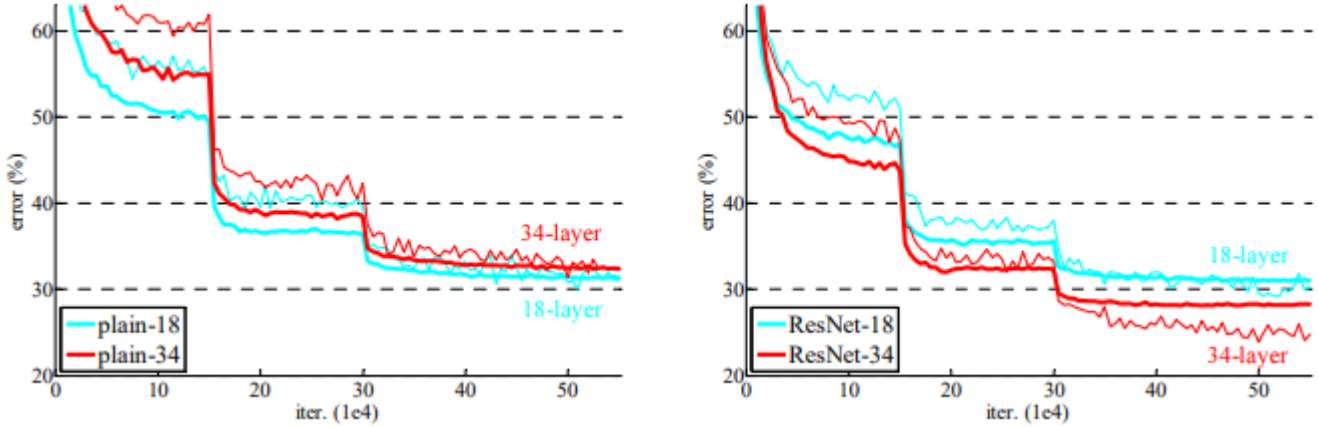

PlainNet	ResNet
34-layer plain 모델의 학습 에러율이 18-layer plain 모델의 학습 에러율보다 더 높음	34-layer ResNet 모델의 학습 에러율이 18-layer ResNet 모델의 학습 에러율보다 더 낮음 1. Degradation 문제 해결 : 상당히 낮은 training error 율을 보이고, validation data 에 대해서도 generalizable 2. 18-layer ResNet 도 18-layer plain net 보다 빨리 수렴(converge)한다. ResNet은 early stage 에서 optimizer 의 빠른 수렴을 도와줌

Experiments – ImageNet Classification – Identity vs. Projection Shortcuts

Shortcut Connection Options	increasing dimensions	other shortcuts
option 1	zero-padding	identity shortcut connections
option 2	projection shortcuts	identity shortcut connections
option 3	모든 shortcut connections 에 대해서 projection 사용	

Experiments – ImageNet Classification – Deeper Bottleneck Architectures

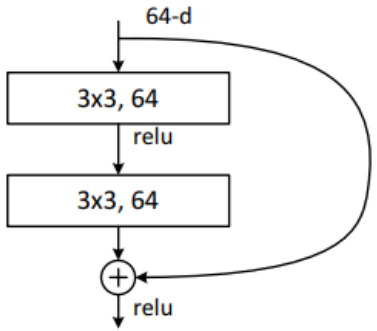

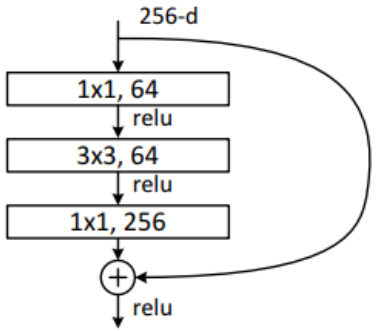

- Bottleneck block : 34-layer ResNet의 block 에서, 2번째 3x3 convolution을 빼고,
  처음과 끝에 1x1 convolution layer 추가함
  - 1x1 layer 는 dimension 의 감소, 증가에 모두 대응할 수 있음

- time complexity 는 비슷함
  - 34-layer ResNet : 3.6 x 10^9 FLOPs
  - 50-layer ResNet : 3.8 x 10^9 FLOPs

- parameter-free identity shortcut 사용 (shortcut connection 의 option 2)

- 152-layer ResNet의 경우에도 VGG-16/19 nets 보다 낮은 complexity 를 가짐

- 6개의 서로 다른 depth 를 가진 ResNet 모델을 ensemble, ImageNet testset 에 대해서 3.57% top-5 error 달성

2

Kaggle flower classification dataset info

Dataset information

Categories	Details
# classes	104 classes
# images	51012 train images, 14848 validation images
size of images	192x192, 224x224, 331x331, 512x512
pixel mean (train dataset)	[0.485, 0.456, 0.406]
pixel std (train dataset)	[0.229, 0.224, 0.225]
image augmentation (train)	1. The image is resized with its shorter side randomly sampled in [256, 480] for scale augmentation 2. 224x224 crop is randomly sampled from an image 3. Random horizontal flip 4. Per-pixel mean subtracted(normalize) : For pretrained resnet50, ImageNet mean, std are required For scratch training for plain34, resnet34, resnet50, flower dataset mean, std are required 5. Standard color augmentation is used : Not apply color augmentation, I thought color is an important feature for classification of flowers
image augmentation (val)	1. Centor crop image, size 224x224 2. Per-pixel mean subtracted(normalize)

3

34-layer plain nets vs 34-layer ResNet

Learning curve – 34-layer plain nets vs 34-layer ResNet

Net Type	Learning Curve(Loss)	Learning Curve(Accuracy)
34-layer **plain nets**	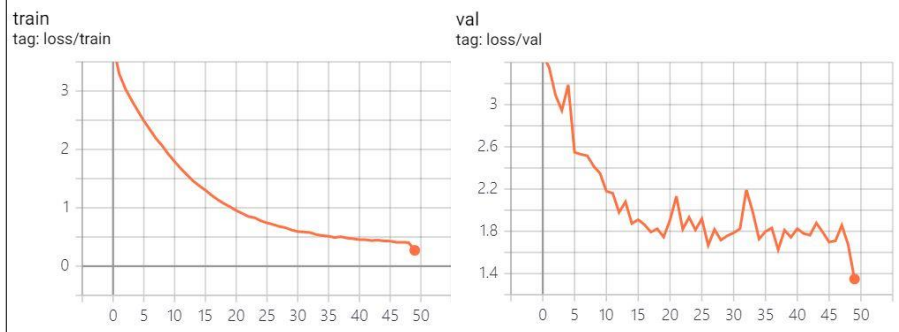	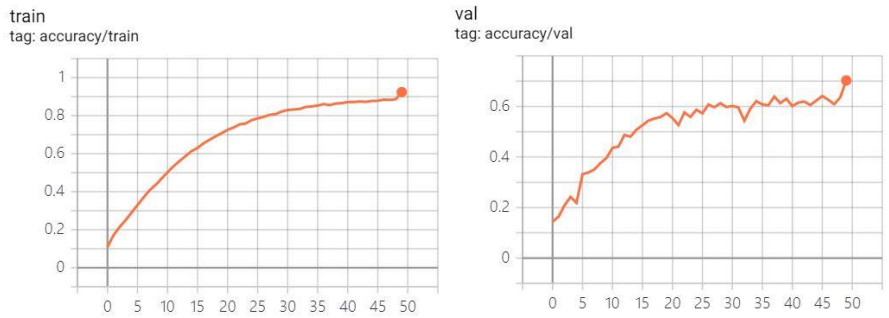
34-layer **ResNet**	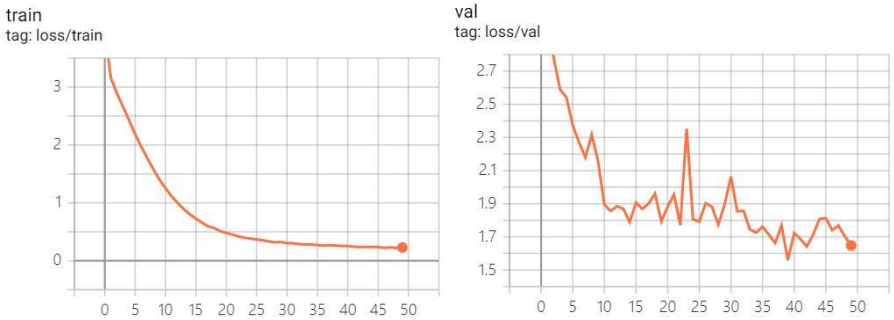	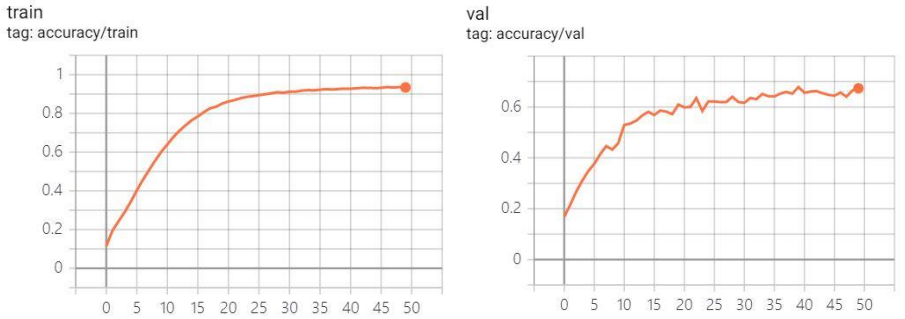

- **LR scheduler** : 10 epochs 동안 validation loss 가 min 값을 찍지 못하면 lr /= 10, 전체 50 epochs 학습
- **Convergence rate analysis** : loss, accuracy 모두 ResNet 에서 더 빠르게 수렴
- **Loss/accuracy analysis** : plain-net 의 경우 (27, 37, 47) epoch 에서 3번의 learning rate 감소 (0.1-> 0.01 -> 0.001 -> 0.0001), ResNet의 경우 (33, 49) epoch 에서 2번의 learning rate 감소, 최종적으로 50 epoch 에서 더 높은 accuracy 를 달성(plain 0.7, resnet 0.68)
- Validation loss를 기준으로 한 patience = 10 인 ReduceLROnPlateau scheduler를 사용했는데, 전체적으로 학습 epoch을 늘리고, patience 값을 더 낮게 조정해야 할 필요성을 느꼈습니다.

Learning curve – 34-layer plain nets vs 34-layer ResNet (more training epochs, less patience for lr scheduler)

Net Type	Learning Curve(Loss)	Learning Curve(Accuracy)
34-layer **plain nets**	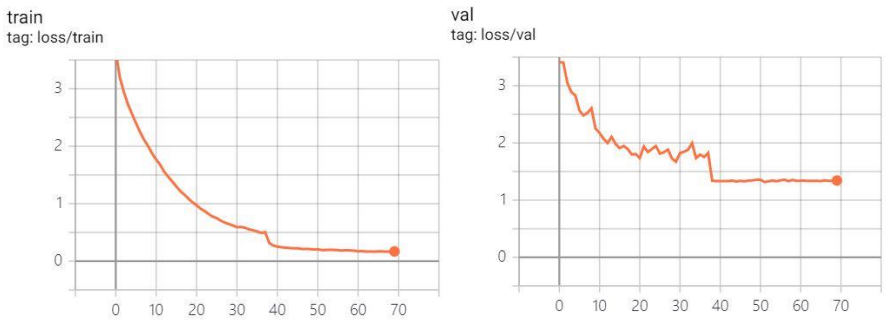	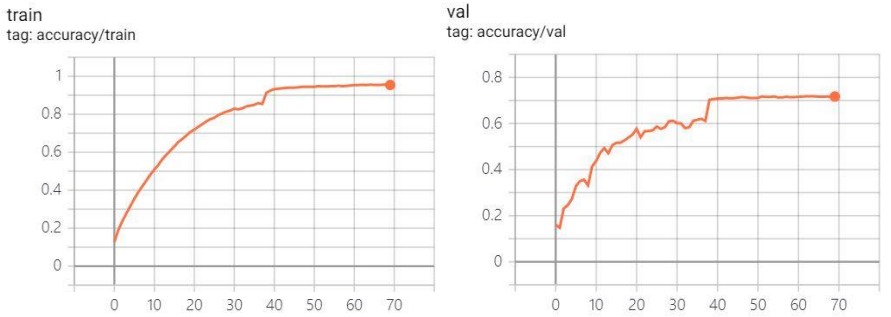
34-layer **ResNet**	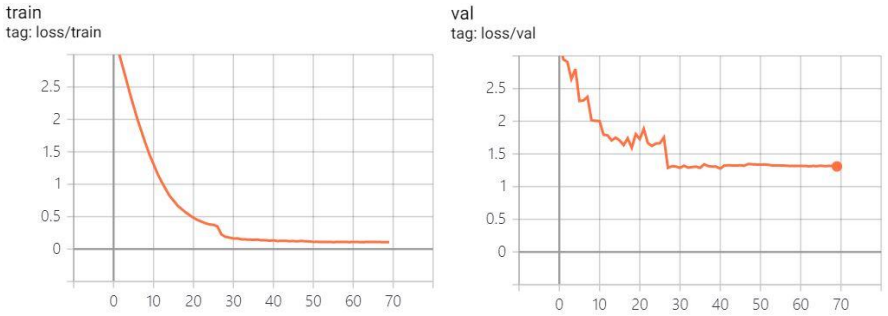	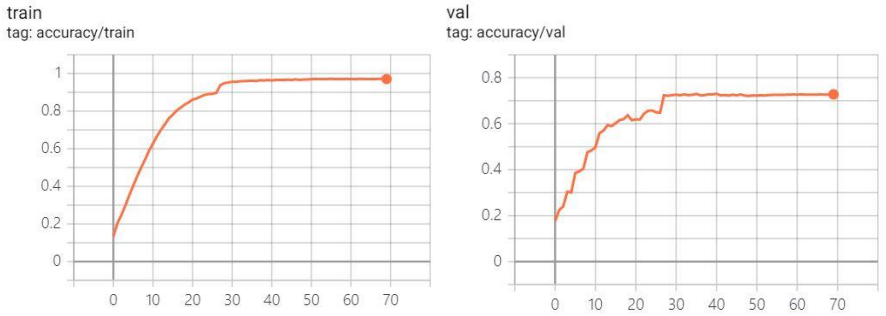

- **LR scheduler** : 7 epochs 동안 validation loss 가 min 값을 찍지 못하면 lr /= 10, 전체 70 epochs 학습
- **Convergence rate analysis** : ResNet이 plain net보다 10epoch 정도 더 빠르게 수렴
- **Loss/accuracy analysis** : ResNet의 최종 accuracy 가 plain net의 최종 accuracy 보다 근소하게 높음(ResNet 72%, PlainNet 71%)
- 성능도 좋아지고 무엇보다도 모델 자체가 훨씬 빠르게 수렴되기 때문에, Flower Dataset의 학습에 있어서 residual connection 을 사용하는 것이 좋다는 결론을 내렸습니다.

4

Basic block(34-layer ResNet) vs BottleNeck(50-layer ResNet)

Learning curve – Basic block(34-layer ResNet) vs BottleNeck(50-layer ResNet)

Net Type	Learning Curve(Loss)	Learning Curve(Accuracy)
Basic block (34-layer ResNet)	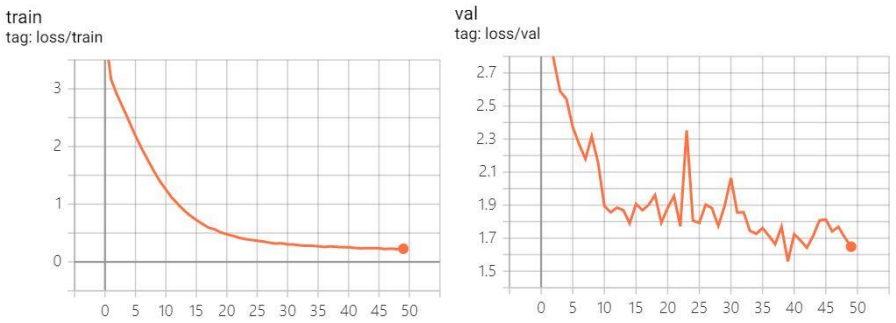	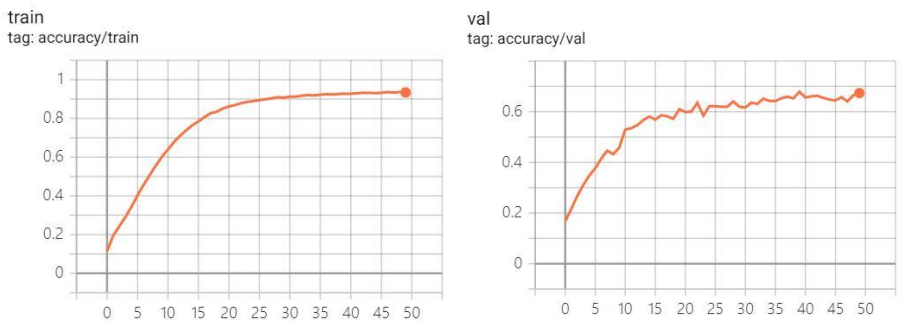
BottleNeck (50-layer ResNet)	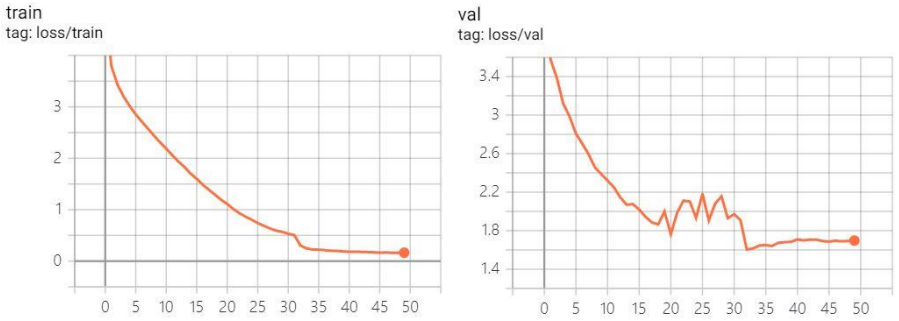	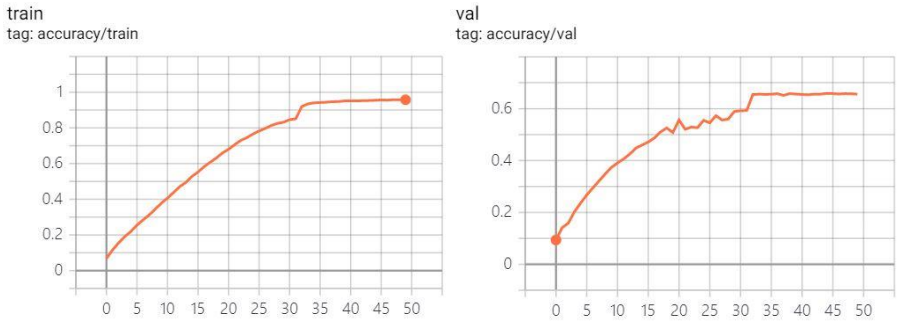

- **LR scheduler** : 10 epochs 동안 validation loss 가 min 값을 찍지 못하면 lr /= 10, 전체 50 epochs 학습
- **Convergence rate analysis** : ResNet block architecture 는 Basic Block을 사용했을 때, 더 빠른 수렴을 보임
- **Loss/accuracy analysis** : BottleNeck에서 Validation loss 가 튀지 않고 안정적으로 수렴했고, 두 모델 전부 learning rate 가 2번 감소해서 epoch 50 에서는 최종 0.001의 learning rate 로 학습됨, 50epoch 에서 최종 accuracy 는 basic block이 더 높음
- 두 모델 전부 최종적으로 수렴이 덜 된 상태에서 학습을 종료했기 때문에, **34-layer plain nets vs 34-layer ResNet** task 와 마찬가지로 전체적으로 학습 epoch을 늘리고, patience 값을 더 낮춰서 학습을 진행했습니다.

Learning curve – Basic block vs BottleNeck (more training epochs, less patience for lr scheduler, trial 1)

Net Type	Learning Curve(Loss)	Learning Curve(Accuracy)
Basic block (34-layer ResNet)	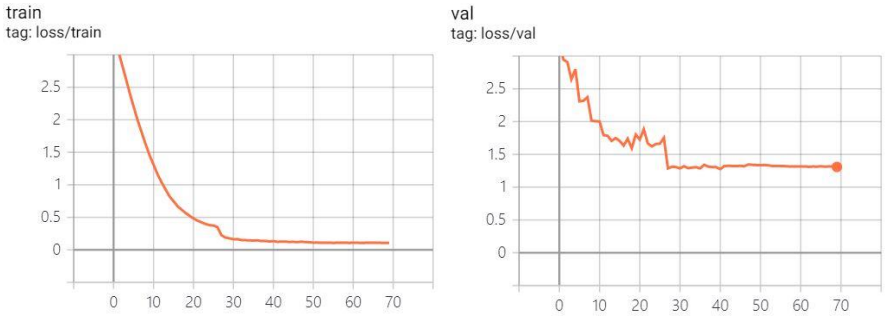	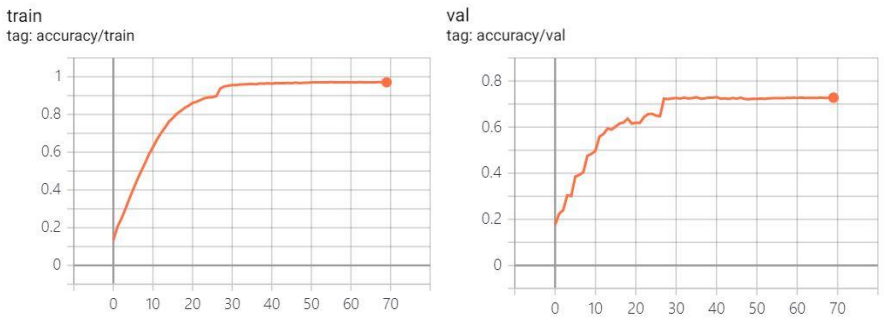
BottleNeck (50-layer ResNet)	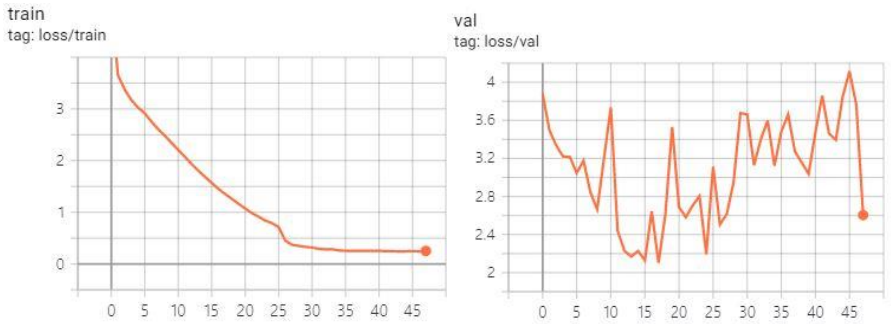	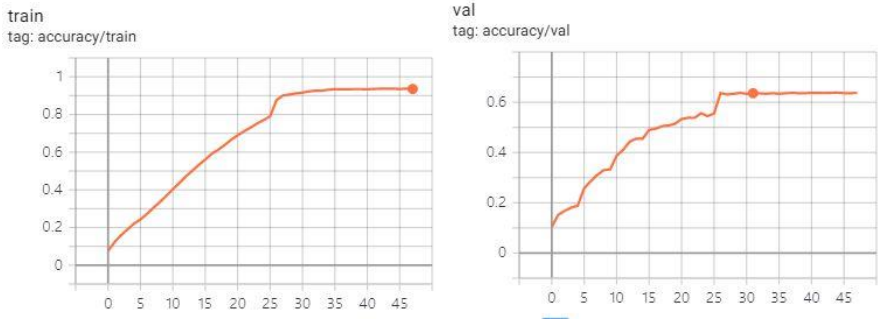

- **LR scheduler** : 7 epochs 동안 validation loss 가 min 값을 찍지 못하면 lr /= 10, 전체 70 epochs 학습
- **Convergence rate analysis** : ResNet50모델의 validation loss가 17epoch 때 최소값이었는데 24epoch까지 감소하지 않고, 높은 상태에서 learning rate 가 감소해서 model weight가 local minima에 빠짐
- 1) 현 LR Scheduler(ReduceLROnPlateau)의 patience 를 더 늘리고 학습 epoch을 늘림
- 2) 다른 LR Scheduler 를 사용하거나 학습이 정상적으로 된 checkpoint 에서 시작해서 다시 시작
- 1) 을 하기에는 시간이 부족하고, 2)를 적용하기에는 epoch 10 부터 validation loss 가 크게 튀어서 처음부터 그대로 진행했습니다.

Learning curve – Basic block vs BottleNeck (more training epochs, less patience for lr scheduler, trial 2)

Net Type	Learning Curve(Loss)	Learning Curve(Accuracy)
Basic block (34-layer ResNet)	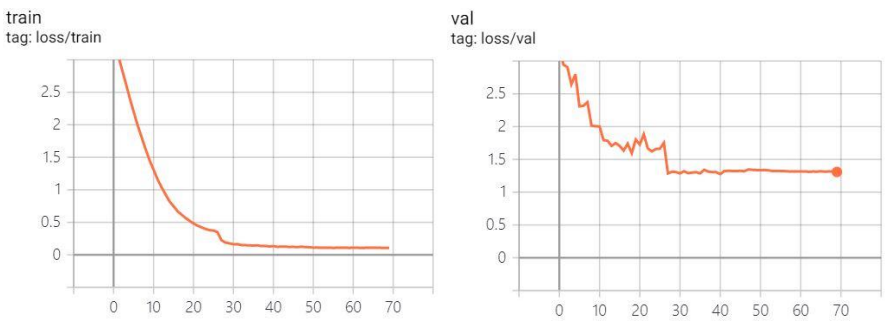	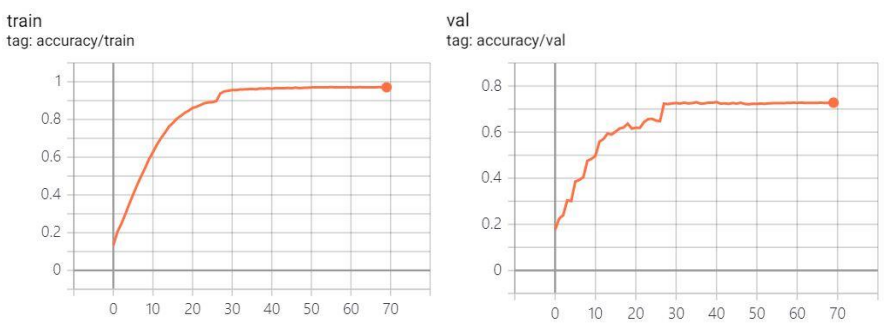
BottleNeck (50-layer ResNet)	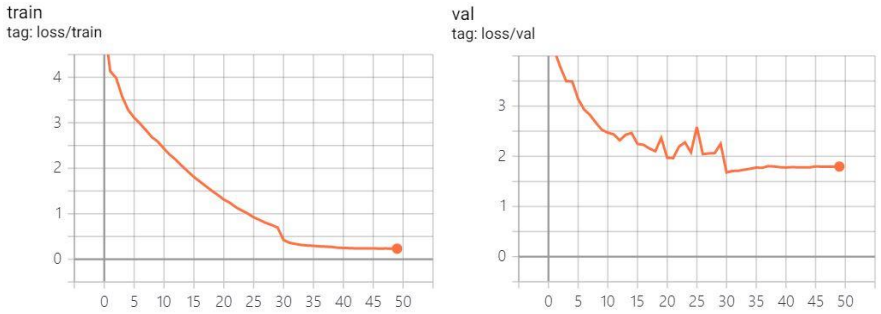	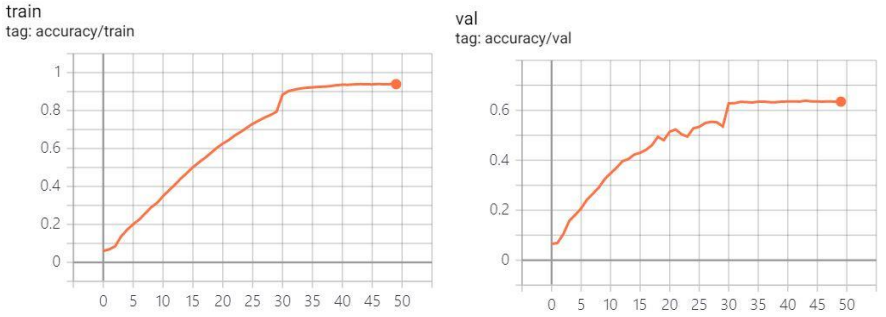

- **Convergence rate analysis** : Basic Block에서 3 epochs 정도 더 빠르게 validation loss가 수렴, 두 모델 전부 30Epoch 이전에 수렴이 되어서 50-layer ResNet 모델은 50Epoch 까지만 학습 진행
- **Loss/accuracy analysis** : 34-layer ResNet의 validation accuracy 가 50-layer ResNet의 validation accuracy 보다 약 7~8% 정도 높음
- Kaggle Flower Dataset의 scratch training 에서는 BottleNeck보다 BasicBlock을 적용하는 것이 좋다는 결론을 내렸습니다.
  (Tensor initialization, dataloader sampler 등 여러 요인에 의해 accuracy 가 달라질 수 있어서, 추가적인 검증 필요)

5

Train from scratch vs Transfer learning from ImageNet

Learning curve – Train from scratch vs Transfer learning from ImageNet

Net Type	Learning Curve(Loss)	Learning Curve(Accuracy)
Train from scratch (50 epochs, learning rate scheduler patience 7, init lr 0.1)	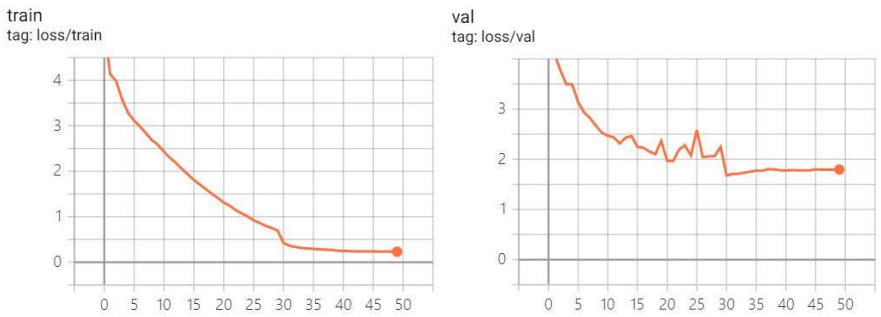	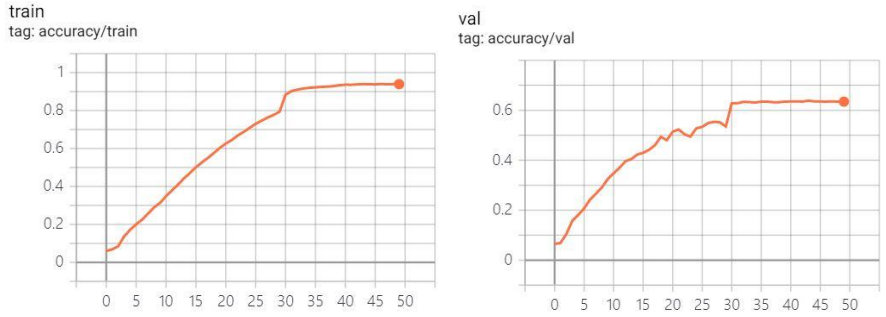
Transfer learning from ImageNet (50 epochs, learning rate scheduler patience 10, init lr 0.01)	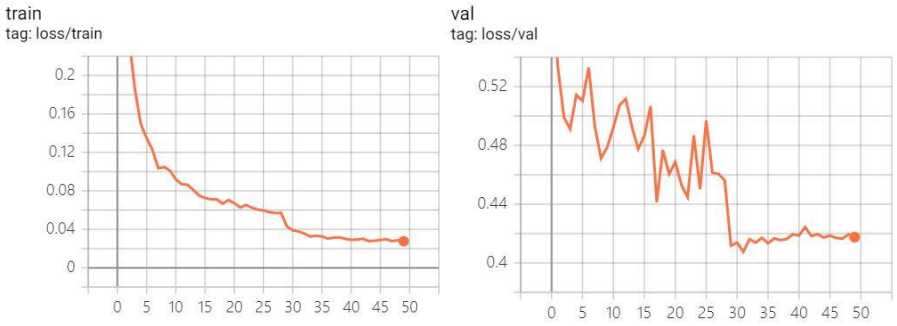	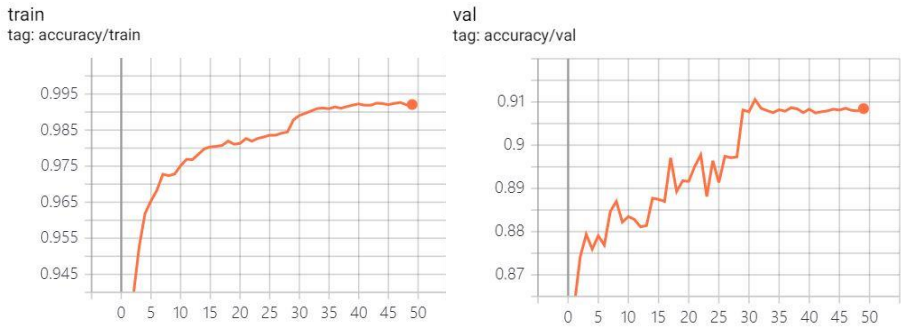

- **Implementation** : Transfer learning model 에서는 마지막 fc-layer 를 제외한 나머지 backbone에 ImageNet Pre-trained weight 를 사용
- **Convergence rate analysis** : transfer learning 의 경우에는 28epoch 에서 learning rate 의 감소가 일어났고 31epoch 에서 완전히 수렴함
- **Loss/accuracy analysis** : transfer learning model이 학습 시작부터 학습 종료까지 50Epochs 전부 loss, accuracy 가 좋았음
- Google의 BiT(Big Transfer), ViT(Visual Transformer) 와 같이 최대한 많은 이미지로 pre-train 하고(JFT-300M dataset), pre-trained weight에서 특정 dataset, task로의 transfer learning이 강력한 성능을 발휘한다는 것을 보여준 바 있습니다. 강력한 성능의 모델을 위해서는 large-scale supervised pre-training이 중요하다는 것을 다시 한번 경험하는 계기가 되었습니다.

6

TODO

TODO

Categories	Details
Hyper parameters	- 처음에는 train epochs 를 50으로 설정했지만, 실제 ResNet paper 에서는 600,000 iterations 까지 학습을 진행함 - We use SGD with a mini-batch size of 256. The learning rate starts from 0.1 and is divided by 10 when the error plateaus, and the models are trained for up to 60 × 10^4 iterations - 600,000 batch x 256 images/batch x (1/128,000) epoch/images = 120 epochs - Train epochs 를 50에서 원래 논문처럼 120 Epochs 까지 학습하면 더 뚜렷한 convergence rate 를 확인할 수 있을 것으로 예상됨 -> ImageNet보다 데이터셋 사이즈가 작아서 실제로는 70Epoch 의 학습도 충분했음 - LR scheduler 의 patience 값 감소(validation loss 가 진전이 없는 상태에서 더 빠른 convergence를 유도) - 실제로 LR scheduler의 patience 값을 10에서 7로 바꾸고, 학습을 70 Epoch 까지 해서 모델 수렴 결과를 볼 수 있었음
Preprocess	- Color transform 사용 여부에 따른 ablation study - Preprocess tensor normalization 에서 train, validation dataset 의 pixel mean, std를 한번에 구하고, cross validation 적용
Test	- Test dataset 에 대한 testing process 구현 - 10-crop testing (horizontal flips x FiveCrop) 적용 - 마지막 fc layer 대신 convolution layer를 사용한 Fully-convolution form 을 통한 multiple scales size {224, 256, 384, 480, 640} 에서 테스트
Ensemble	- plain34, resnet34, resnet50, pre-trained resnet50 각 모델의 classification 결과의 vote 기반 ensemble 을 통한 성능 향상
Code Refactoring	- Tensorboard 에서 epoch 에 따른 loss 를 바로 확인할 수 있도록 SummaryWriter hook 에 추가 - Validation loss 가 min 값일 때만 Checkpoint 저장하도록 변경 - Hyper parameter, Image preprocessing pipeline 에 대한 configuration file 작성 및 연동 - Kaggle submission format에 따른 test result csv builder script 작성 - 특정 checkpoint 부터 이어서 학습하는 script 작성 필요